

探海灵眸 SeaSight 总控计划书

区域海上环卫治理系统

国奖候选工程基线

版本	2.1
编制日期	2026-09-19
参赛赛道	海洋科创 / 海上智能装备与无人系统，兼顾数字赋能现代渔业与海洋绿色低碳创新
文档定位	研发、产品、商业、答辩、验收和智能体分派的唯一总控基线
当前评分	80/100（内部红队；不是赛事官方评分）
章节数量	16 个一级章节

本文档严格区分代码/测试、合成验证、用户真实验证和商业成交证据；所有对外数字必须回到证据台账。

目录

页码以本文件最终渲染结果为准。

章节	页码
0. 先给结论	-
1. 证据分级与表述纪律	-
2. 评委视角：这个项目现在能打多少分	-
3. 产品经理视角：谁买、谁用、为什么持续使用	-
4. 当前项目事实基线	-
5. 智能体开发比赛的核心方案	-
6. 感知、执行与数据闭环	-
7. 核心指标体系	-
8. 商业模式与市场验证	-
9. 十二周推进计划	-
10. 团队与执行体系	-
11. 风险清单	-
12. 比赛答辩设计	-
13. DeepSeek Harness 分工开发方案	-
14. 总体验收标准	-
15. 立即执行顺序	-

0. 先给结论

探海灵眸不是一个单台清洁船项目，而是一套面向县域海上环卫治理的“感知、决策、执行、核算”区域级软件与装备系统。当前项目已经具备较强的软件工程底座：事件接入、幂等去重、时序降误报、空间派单、任务状态机、MQTT 上下行、ACK 超时重派、Redis Streams 消费与 PEL 回收、日报聚合、认证、审计和可视化页面均有真实代码与自动化测试。Agent Runtime 已形成 E1 级确定性内核，并通过 E2 软件集成验收：真实 HTTP、角色权限、PostgreSQL 仓储、工单/事件写入、WRITE 审批、幂等重放和进程重启后的已完成 run 只读回放均已实测；当前仍不是生产级、分布式、高可用运行时，也不声称未完成 run 可在重启后续跑。

但项目距离“经得起智能体开发和创新创业比赛严审”仍有明确缺口。当前最重要的三个缺口不是页面数量，而是：

1. 智能体已完成 E1 级确定性闭环、固定场景评测和 E2 真实状态软件集成验收，但尚未接入真实模型、真实设备、分布式调度和生产级高可用基础设施。
2. 真实海域数据、机器人硬件、现场试点和客户协议尚未形成证据链；OpenCV 评测因测试清单为空，当前必须是 `not_evaluated`。
3. 商业数字目前是 E0 测算或 E1 外部引用，不是订单、收入或采购结论，必须继续按台账口径表达。

因此，本计划书不承诺“必得国奖”。国奖无法由任何文本或单方面努力保证，但可以通过真实问题、技术深度、可复现证据、产品闭环、商业验证和现场表达，把项目提升到稳定的国奖候选水平。按当前证据，内部红队评分约 80/100；目标是补齐 E3/E4 证据后进入 86/100 以上的候选区间，并消除所有“一问就穿”的诚信风险。

1. 证据分级与表述纪律

全文和对外材料统一使用以下五级证据。任何能力描述必须能对应到证据级别，不能把规划写成现状。

级别	含义	可对外使用的表述
E0	只有想法、文档或接口草案	“规划中” “拟建设”
E1	有代码、单元测试或确定性仿真	“已实现，已通过软件测试”
E2	多模块软件联调，使用合成数据或模拟设备	“已完成合成环境闭环验证”
E3	真实设备、真实海域或真实用户参与验证	“已完成现场验证”
E4	有合同、订单、回款、验收报告或复购	“已形成商业验证”

以下表述在取得对应证据前禁止使用：

- 禁用“视觉大模型已经部署”，当前真实路线是 OpenCV 传统视觉检测。
- 禁用“机器人已实现 7×24 自主清理”，当前只有软件链路和合成或模拟验证。
- 禁用“智能体已经在线协同、生产级高可用或可无人值守运行”，当前只能写成“已完成 E1 级进程内确定性 Agent Runtime 与固定场景评测”。
- 禁用“已有客户、订单、收入、试点成效”，除非附件中存在合同、协议、验收或财务凭证。
- 禁用把“76%”写成识别精度、召回率或泛化准确率；它只是时序链路误报抑制率，分母是输入检测数。
- 禁用把“约 17 万元”写成 SeaSight 售价或成交价；该数只来自商业台账 F-05 的 WasteShark 外部报价换算，原报价核验为 E1、汇率折算为 E0。

2. 评委视角：这个项目现在能打多少分

以下评分不是任何赛事的官方评分表，而是把创新创业比赛常见的评审逻辑、智能体专项评审逻辑和真实项目尽调逻辑合并后的内部红队评分。它的用途是找短板，不是自我表扬。

维度	权重	当前得分	评分理由	达到国奖候选的判据
场景与政策契合	10	9	连江养殖区、海漂垃圾、海上环卫和数字治理高度吻合	保留，并补齐政策文件、调研记录和场景照片
问题真实性与需求强度	10	8	有明确使用者和现有治理流程，但本地访谈与量化台账不足	形成 3 类用户访谈、现有流程成本台账和需求优先级
技术与产品创新	20	16	区域级闭环、空间调度和确定性 Agent Runtime 已落地，但感知评测尚无样本、硬件未验证	真实 Agent Runtime、空间调度闭环和可量化检测评测
工程实现与可信度	20	18	1012 项通过、契约漂移/自证、浏览器/故障演练和 Agent E2 集成验收可复现；硬件与现场证据仍弱	软件全绿、模型有独立评测、至少一次真实设备或海域联调
智能体原生能力	15	15	Run、Step、Tool、Policy、Approval、Replay、Eval 已落地，23/23 固定场景通过；新增真实 HTTP/PostgreSQL/审批/幂等/重启只读回放 E2 验收，非生产级	工具调用、观察、验证、重规划、审批、记忆、回放全部可实证
商业闭环与单位经济性	15	7	台账、访谈和询价模板已建立，但成本、付费意愿和采购路径未验证	获得意向、试点预算或真实询价，核心假设有敏感性分析
团队与执行力	5	3	有明确技术负责人和工程交付基础，成员与职责仍不完整	补齐团队成员、导师、外部顾问和阶段成果记录
社会与生态价值	5	4	减人、降风险、可量化治理的价值清楚	形成可复核的碳、生态或治理绩效口径
合计	100	80	强软件原型与 Agent E1/E2 闭环，弱真实感知、硬件、现场和商业验证	86 分以上且不存在诚信红线

2.1 评委最可能提出的十个问题

1. “你们说检测有 76% 抑制率，抑制了什么，分母是什么，真海况测过吗？”
2. “六个智能体分别运行在哪里，谁规划、谁调用工具、失败后如何重规划？”
3. “如果没有大模型或外网，系统还能工作吗？”
4. “机器人是否已经做出实物，最大抗风浪等级、续航、载重和故障率是多少？”
5. “平台发现垃圾之后，为什么不是人工点一下派单，而必须是智能体？”
6. “政府现有每吨清理成本是多少，你们的报价依据来自哪里？”
7. “本地数据集现在有多少张，标注一致性如何，是否存在独立测试集？”
8. “系统如何防止 Agent 误派、重复派单和越权操作？”
9. “试点协议、意向书、测试报告或验收报告在哪里？”
10. “如果机器人离线、MQTT 断连、模型误报或 Redis 故障，用户看到什么，谁负责兜底？”

2.2 直接影响奖项等级的红线

- 任何静态状态被包装成实时运行状态。
- 用 MD5 伪推理结果冒充真实模型输出。
- 将测算价格写成客户成交价。
- 将合成海面测试写成真实海域验收。
- 只有“AI”“大模型”“智能体”标签，没有输入、工具、观察、验证和终止条件。
- 答辩系统无法现场复现，或者只能播放预录视频。
- 文档中的测试数量、准确率、成本与当前代码或数据不一致。
- 项目没有明确购买者、预算科目和商业模式。

3. 产品经理视角：谁买、谁用、为什么持续使用

3.1 用户和购买者不是同一个人

角色	核心任务	当前痛点	产品承诺	是否付费方
县海洋与渔业主管部门	监管、考核、汇报、专项治理	数据分散，治理成效难量化，缺少统一台账	一张图掌握事件、任务、清理量和风险	是
沿海乡镇操作员	发现、派单、督促、闭环	巡查靠人，跨队伍协调靠电话，过程难追溯	少点几次、少打几个电话，异常自动到人	预算执行方
海上环卫作业队	接单、航行、打捞、回传	空驶多、临水风险高、任务优先级靠经验	减少空驶和重复航行，保留人工接管	直接用户
养殖户或渔民	上报、回收、领取补贴	上报流程不透明，回收收益兑现慢	低门槛上报，记录可查，积分或补贴可核销	参与方
平台管理员	设备、权限、阈值、审计	设备状态和系统异常不可见	全链路观测、回放、审批和审计	运维方
算法或运维工程师	模型、数据、故障处理	离线模型与线上系统割裂	数据闭环、版本管理、评测和热更新	技术用户

项目当前的主要购买者是县级主管部门或乡镇政府，主要高频用户是乡镇操作员和海上环卫作业队，养殖户是治理网络的参与节点，不是短期内的主要收款对象。

3.2 核心 Job To Be Done

当辖区海面出现影响航道、养殖、岸线和旅游环境的漂浮垃圾时，我要在有限人力和预算下，快速确认问题、派出合适设备、跟踪执行过程，并向上级证明问题已经闭环，而不是只看到一堆视频和告警。

产品必须回答四个连续问题：

- 1. 问题是否真实存在，证据是什么？
- 2. 应该派谁、何时去、代价是多少？
- 3. 执行是否顺利完成，失败后怎么处理？
- 4. 最终清理了什么，花了多少钱，是否值得继续采购？

3.3 产品主线

发现
摄像头/无人机/人工上报
-> 证据帧、类别、置信度、空间位置、时间
确认

时序验证、空间聚类、历史对比

-> 形成可信事件，抑制单帧误报

决策

Agent 读取事件、设备、任务、天气和历史

-> 生成计划，经过策略守卫和审批策略

执行

MQTT 下发、ACK、导航、作业、异常监控

-> 任务状态和轨迹持续回传

验收

机载复核、证据回传、重量录入、人工确认

-> 事件、任务、材料和费用一致

核算

日报、月报、热力图、成本和服务绩效

-> 支撑考核、续约和扩大投放

3.4 产品北极星指标

第一阶段北极星指标不使用“识别框数量”或“页面访问量”，而使用：

单位有效成本下完成闭环并经过证据确认的垃圾清理量。

计算公式：

$$\text{单位闭环成本} = \frac{\text{设备折旧} + \text{能源} + \text{运维} + \text{人工协同} + \text{通信}}{\text{已验收清理量}}$$
$$\text{有效闭环率} = \frac{\text{状态为 done 且存在复核、重量、时间和证据的任务数}}{\text{已派发任务数}}$$

在当前阶段，先建立可计算的数据链路，再使用真实试点数据替换估算值。

4. 当前项目事实基线

4.1 已具备的真实能力

模块	当前实现	证据类型	对外边界
事件接入	FastAPI、Schema 校验、设备校验	E1	已实现软件链路
幂等去重	(device_id, seq) 和 event_id 双重判重	E1	已验证重复上报
时序降误报	抽帧、目标跟踪、连续命中、冷却	E1/E2	76% 仅是 “被过滤检测数 / 输入检测数” 的时序抑制率，不是识别精度或召回率
OpenCV 检测	背景建模、颜色、形状和 ROI	E1	传统视觉代码，不等于训练模型；独立测试集为空，当前评测结果为 not_evaluated
空间派单	在线、电量、仓容、KNN、类别加权	E1	依赖设备数据质量
防抖合并	距离和时间窗口合并任务	E1	参数仍需现场标定
任务状态机	pending 到 done 的合法迁移	E1	已覆盖非法迁移
MQTT 上下行	任务下发、ACK、进度和遥测	E1/E2	可使用模拟设备联调
失败恢复	ACK 超时回退、换车、PEL 回收	E1	真实网络仍需压测
Agent Runtime	Run、Step、Tool、Policy、Approval、Replay、Eval；默认内存仓储，可选 SQL 持久化仓储；真实 HTTP/PostgreSQL/审批/幂等/重启只读回放已验收	E1/E2	E1 为确定性内核；E2 已验证已完成 run 的持久化读取与回放，不声称未完成 run 续跑，非生产级、分布式或高可用
Agent API 与前端	运行、步骤、工具、审批、评测和取消接口接入控制台	E1	浏览器回归 3/3 通过；权限、取消二次确认和详情刷新恢复已形成截图与 JSON 证据
Agent 固定评测	23 个确定性场景，23/23 通过，0 skipped，无网络、无真实模型、无真实设备	E1	证明内核契约、持久化恢复、故障注入和回放，不证明真实业务成功率
数据报表	事件、任务、重量按日聚合	E1	coverage_area 已改为 nullable；无来源时返回/导出为空，不写 0
认证与审计	角色、辖区、写权限、审计日志	E1	仍需完善审批链路
前端页面	大屏、事件、任务、设备、报表、分析、Agent 控制台	E1	Agent 页面已改为真实 API 状态；活跃运行取消、viewer 审批禁用、运行详情刷新恢复已通过浏览器回归
软件测试	1012 项通过、0 跳过、0 失败	E1	测试全绿；剩余第三方 warning 已记录并可解释

4.2 当前测试基线的准确口径

2026-09-19 对根目录执行：

```
.\.venv-analysis\Scripts\python.exe -m pytest -q -rs
```

实际结果：

```
1012 passed, 1 warning in 71.79s (0:01:11)
```

收集总数为 1012 项，当前为 1012 passed / 0 skipped / 0 failed。

健康降级测试固定指向无监听端口，不再依赖开发者机器上是否恰好启动了 Redis 或 PostgreSQL；“全部依赖不可用”的断言现在每次都会真实执行。

剩余 1 条 warning 为：

- Starlette TestClient 对 anyio.abc.BlockingPortal 的弃用告警，属于第三方依赖。

历史上曾出现的 Pillow 缺失、Windows GBK 编码和 asyncpg 关闭路径告警已经修复；当前文档只以本次 0 failed 的原始结果为准。

4.3 当前不可宣称的能力

项目	当前真实状态	正确口径
YOLO 或视觉大模型	无数据、无训练权重、无现场评测	接口已保留，当前采用 OpenCV 传统视觉
Agent Runtime	已有 E1 确定性闭环、23/23 固定场景评测和 E2 真实状态集成验收；在线评测源为 latest_v2.json；持久化仓储支持受控重启读取与幂等重放	可写“本地确定性 Agent Runtime、E2 软件集成与已完成 run 重启只读回放已实现”；不可写生产级、在线协同、未完成 run 续跑或现场自主运行
机器人硬件	无在库实物交付证据	原型方案与外部协作项
无人机闭环	无设备接入与试点证据	规划能力
真实海况精度	独立测试清单为空，OpenCV 报告为 not_evaluated	当前没有可对外报告的真实精度，禁止用 76% 代替
覆盖面积	字段已改为 nullable，无来源时不输出数值	缺少可靠数据源时导出留空，禁止写 0 或估算冒充实测
试点与客户	无合同、订单或验收附件	仅有测算和意向目标
7×24 运行	软件具备持续运行设计	已完成链路验证，不代表现场无人值守

4.4 当前证据包与完成度

证据包	当前状态	可复现材料	对外上限
软件回归	已完成	pytest -q -rs: 1012 passed / 0 skipped / 0 failed	E1
前端构建与浏览器集成	已完成	npm run build 通过; 浏览器 E2E 15/15 (真实登录、六页读取、CSV、权限、MQTT 降级)	E1
契约漂移	已完成	check_contract_drift.py: 通过 26、警告 0、失败 0	E1
受控故障演练	已完成	4/4 组、127/127 用例; 健康降级、ACK 启动恢复、孪生闭环、持久化/API 幂等	E1; 不代表真实 broker / 硬件 / 公网故障
契约自证	已完成	12 项缺陷注入全部捕获, 0 未捕获, 字节级还原	E1
Agent 内核	已完成	23 个固定场景全部通过、0 skipped; 覆盖持久化恢复、模型回退、轨迹回放、审批交接和设备故障恢复	E1
Agent 数据与 API	已完成	默认内存 Runtime、可选 SQL 持久化仓储、ORM、迁移脚本、冻结 API 与权限测试	E1
Agent 前端	已完成 E1 浏览器回归	真实 Run、Step、Tool、Eval、Policy、取消和审批接口; 3/3 交互场景通过	E1; 真实登录与 API 拦截构造状态, 不等于真实用户试点
Agent 真实状态验收	已完成	scripts/agent_real_state_acceptance.py: 129/129; 真实 HTTP/权限/PostgreSQL/工单/事件/WRITE 审批/幂等/重启只读回放	E2; 合成事件、进程内 Runtime, 不覆盖真实设备/海域/未完成 run 续跑
感知评测	未形成样本证据	artifacts/metrics/opencv_latest.json 为 not_evaluated	E0/E1, 不可报告精度
数据完整性	已完成	coverage_area nullable、清空历史假 0、CSV UTF-8 BOM 与空值验收	E1
商业证据	模板完成, 实地证据缺失	台账、访谈模板、询价模板	E0/E1, 无 E3/E4

当前最适合国奖答辩的叙事不是“已经有 AI 大模型和机器人”，而是“团队用严格的证据纪律，把一个区域治理问题做成了可运行、可回放、可评测、可审计的软件与 Agent 闭环”。真实感知、硬件和商业价值仍需通过现场证据补足。

5. 智能体开发比赛的核心方案


5.1 为什么不能继续把模块叫“智能体”

识别、调度、报表、巡检、告警和审计都有价值，但它们是能力模块，不是独立智能体。真正的智能体必须具备：

- 从目标出发生成计划。
- 在受控工具集合中选择并调用工具。
- 读取工具结果并观察环境变化。
- 判断计划是否成功，失败时重规划。
- 在关键动作前执行策略校验和人工审批。
- 在明确条件满足后终止，并记录终止原因。
- 全过程可追踪、可回放、可评测、可追责。

项目当前已从“六个静态卡片”转为“一个 E1 级确定性治理 Agent 内核，驱动多个专业工具和受限角色”，并完成 E2 软件集成验收。下一阶段不是继续堆卡片，而是把默认内存、可选持久化的运行时升级为可观测、可恢复的生产候选架构，并接入真实设备与真实数据。

5.2 已落地架构与演进边界



5.3 运行状态机

```

created
-> planning
-> waiting_policy
-> waiting_approval
-> executing
  
```

```
-> observing
-> verifying
-> succeeded
-> failed
-> cancelled
-> expired
```

每次重规划必须产生新 step，不允许覆盖历史步骤。失败原因必须结构化保存，例如 no_robot_available、tool_timeout、policy_denied、approval_rejected、task_conflict 或 max_steps_exceeded。

5.4 Agent 角色

当前第一阶段已经落下一个通用编排器和受限工具集合。角色拆分应继续围绕真实职责和权限边界推进，避免为了“多智能体”而人为拆碎职责。

角色	目标	允许工具	关键约束
总控编排器	判断事件是否处理，组织计划并验证结果	查询、派单、任务、通知、审批	必须有最大步数、超时和终止原因
视觉复核员	复核事件证据与类别可信度	证据读取、历史事件查询	不能直接修改原始检测结果
调度规划员	选出机器人并生成派单计划	设备、空间、任务工具	电量、距离、仓容、辖区硬约束
作业监督员	观察 ACK、轨迹、作业进度和异常	任务、遥测、MQTT 状态	超时只回退或建议，不绕过状态机
异常审查员	识别误报、重复任务、设备异常	审计、评测、通知工具	可建议驳回，不能静默删数据
报表分析员	生成日报和治理绩效	聚合、报表、导出工具	只能从已确认业务数据计算

5.5 工具契约

所有工具使用统一接口，包含名称、版本、输入 Schema、输出 Schema、权限、超时、幂等键、审计事件和错误码。

工具	用途	关键输出	风险级别
event.get	读取事件和证据	事件、类别、置信度、位置	只读
device.query_available	查询可用机器人	距离、电量、仓容、状态	只读
dispatch.plan	生成候选派单方案	方案、评分、拒绝原因	只读
task.create_or_merge	建单或合并任务	task_id、动作、状态	需幂等
task.transition	状态迁移	新状态、时间戳	需策略守卫
mqtt.send_task	下发设备指令	发送结果、消息 ID	需审批或自动策略
mission.observe	查询任务和遥测	ACK、轨迹、电量、仓容	只读
human.request_approval	请求人工审批	审批单 ID、状态	强制审计
metric.query	查询治理指标	指标值、口径和时间窗	只读
report.generate	生成日报	结构化报表和导出记录	需数据完整校验

5.6 确定性内核与可选大模型增强

项目不能依赖外网或商业大模型才能完成核心治理闭环。正确设计是：

- 确定性控制器负责状态、规则、工具调用、超时、重试和终止。
- 规则策略先给出可验证的基线决策。
- 大模型只用于意图理解、异常解释、计划候选生成和自然语言总结。
- 大模型输出必须经过 JSON Schema、策略守卫和工具白名单。
- 模型不可用时自动退回规则模式，系统核心能力不下降。
- 所有模型调用记录版本、耗时、成本和输入输出摘要，不保存不应保存的隐私数据。

这既符合工程可靠性，也避免项目被质疑为“套壳大模型”。

5.7 记忆设计

记忆不是把全部历史塞进提示词，而是分层的业务数据：

记忆类型	内容	作用	保留策略
工作记忆	当前 run 的计划、步骤和观察	完成本次任务	随 run 保留
情景记忆	历史上类似事件和处理结果	相似案例检索	按业务保留期
语义记忆	点位、潮汐、垃圾类别、设备特征	辅助规划	版本化管理
策略记忆	规则、阈值和人工纠正	防止重复错误	必须审批后生效
评测记忆	固定场景、期望轨迹和失败样本	回归测试	永久版本化

记忆写入必须区分“事实”“推断”和“人工确认”，禁止把模型猜测写成事实。

5.8 人工审批

以下情况必须人工审批：

- 超出日常策略的距离、成本或机器人数量。
- 低置信度事件触发高成本任务。
- 跨乡镇辖区调度。
- 机器人故障状态下的强制下发。
- 批量任务、敏感数据导出和阈值修改。

普通、低风险、同辖区、满足全部硬约束的派单可自动执行，但必须产生的证据包括：

- 触发来源。

- 策略版本。
- 候选方案和淘汰原因。
- 工具调用结果。
- 最终动作。
- 结果验证和终止原因。

5.9 数据模型

新增以下核心表，字段由 Alembic 管理：

```
t_agent_run
run_id, trigger_type, objective, status, policy_version,
started_at, finished_at, termination_reason, trace_id

t_agent_step
step_id, run_id, step_no, step_type, decision_summary,
tool_name, tool_version, input_hash, output_hash,
status, latency_ms, error_code, created_at

t_agent_memory
memory_id, memory_type, scope_type, scope_id,
content, confidence, source_type, source_id,
valid_from, valid_to, created_at

t_agent_approval
approval_id, run_id, requested_action, risk_level,
requested_by, decided_by, decision, reason,
requested_at, decided_at
```

不保存模型私有思维链。保存的是可审计的决策摘要、工具输入摘要、工具输出摘要、策略判断和业务理由。

5.10 API

```
GET /api/v1/agents/runtime/status
GET /api/v1/agents/runs
GET /api/v1/agents/runs/{run_id}
GET /api/v1/agents/runs/{run_id}/steps
POST /api/v1/agents/runs
POST /api/v1/agents/runs/{run_id}/cancel
GET /api/v1/agents/tools
GET /api/v1/agents/approvals
POST /api/v1/agents/approvals/{approval_id}/decide
GET /api/v1/agents/evals/latest
```

GET /agents 只能返回真实定义和真实运行状态。运行状态从 Agent Runtime 和持久化运行记录计算，不能写死在字典中。

上述接口已经形成 E1 级实现，AgentsView 已接入真实运行、步骤、工具、审批和评测数据。2026-09-19 完成浏览器回归 3/3：活跃运行首次点击只进入取消确认，第二次点击才发送一次取消请求；viewer 的同意与拒绝按钮禁用并显示无审批权限提示；运行详情关闭后清理 URL 参数，刷新仍保持关闭。该验收使用真实登录与 API 拦截构造状态，只证明前端交互与权限展示，不代表真实用户试点。

5.11 前端信息架构

智能体页面改为四个区域：

- 1. 运行总览：活跃 run、成功率、失败原因、P95 耗时、待审批数。
- 2. 实时轨迹：按步骤展示计划、工具调用、观察、验证、重规划和终止。
- 3. 工具与策略：工具可用性、版本、权限、策略版本和阻断原因。
- 4. 评测与回放：固定场景、期望结果、最近运行差异和回归状态。

界面不得展示伪造的“在线”“运行中”或收益数字。后端不可用时必须显示真实错误和降级状态。

5.12 Agent 测试矩阵

至少覆盖以下场景：

场景	预期结果
事件可信、机器人可用	自动计划、派单、观察、完成
无机器人可用	不误报成功，记录原因，等待补派
工具超时	有重试上限，能重规划或安全失败
机器人 ACK 超时	回退任务并换车，不重复建单
策略拒绝	动作被阻断，产生结构化原因
审批拒绝	run 终止，不发送设备指令
重复触发同一事件	幂等，复用 run 或任务
模型不可用	确定性规则模式继续工作
达到最大步数	安全终止，不无限循环
轨迹完整性	每一步有状态、摘要、时间和结果

5.13 Agent 评测指标

指标	定义	目标
任务成功率	期望业务结果达成的 run 比例	固定评测集不低于 95%
策略违规率	被守卫发现但工具已执行的违规次数	0
工具调用正确率	参数、权限、幂等均正确的调用比例	不低于 99%
无效循环率	超步数或重复无进展步骤的 run 比例	低于 1%
恢复成功率	可恢复异常中成功恢复的比例	不低于 90%
P95 决策耗时	从触发到首个可执行计划的耗时	规则模式目标低于 2 秒
人工接管率	需要人工完成关键决策的任务比例	试点后持续下降
单次决策成本	模型、工具和基础设施成本	可量化、可设预算上限

当前固定评测结果：23/23 场景通过、0 skipped，策略违规率 0，工具调用正确率 100%，轨迹回放匹配率 100%，审批交接成功率 100%；business_success_rate≈65.22% 只是确定性场景终态成功的说明值，不是真实业务成功率。在线消费源为 artifacts/agent_evals/latest_v2.json (schema 2.0)。

WP-18 进一步在真实 HTTP、登录权限、PostgreSQL、工单/事件写入、WRITE 审批、幂等和进程重启只读回放上完成 **129/129** 检查；直接数据库证据为 2 个 succeeded run、25 个 steps、2 个 run state、2 个 task、2 个 dispatched event、1 个 approved 审批。该验收仍使用合成事件，AgentRuntime 在进程内执行，t_agent_run_state 只是审计和重启只读回放镜像，不声称未完成 run 可续跑。上述证据是 E2 软件集成，不能外推为生产 SLA、真实任务成功率或现场自主运行。

6. 感知、执行与数据闭环

6.1 当前识别路线

当前采用 OpenCV 传统视觉检测，包括 ROI、背景建模、白亮通道、暗色通道、形态学、轮廓规则、类别规则和伪置信度。它的价值是零数据依赖、可解释、纯 CPU 可运行，但它不是最终模型路线。

对外必须同时说明：

- 当前实现是 OpenCV 真检测，不是 MD5 stub。
- 合成数据的 76% 抑制率只证明时序链路有效。
- 真实精度、误报率和跨天气泛化尚未验证。
- YOLO 或轻量分类器是数据积累后的候选路线，不写“已经部署”。

6.2 数据集建设

第一阶段只聚焦可定义、可复现的场景：

- 主类别：EPS 泡沫浮球和碎片。
- 次类别：塑胶浮球、瓶体、废旧渔网、绳索和饵料包装。
- 场景：白天、平潮、晴天、阴天、弱反光优先。
- 负样本：浪花、反光、固定浮球阵列、船只、水鸟、岸线物体。
- 每个样本记录点位、时间、天气、潮汐、设备、镜头和标注版本。

数据分集不得随机泄漏：

训练集：用于模型拟合

验证集：用于调参和阈值选择

独立测试集：按日期和点位隔离，只用于最终评测

现场盲测集：交付答辩前封存，现场演示使用

6.3 独立评测指标

每个类别分别报告：

- Precision。
- Recall。
- F1。
- AP50 和 AP50-95。
- 每千帧误报数。
- 事件级发现率。
- 从真实目标出现到确认事件的时间。

- 按天气和光照分层的指标。
- 置信区间和样本量。

禁止只报告一个“准确率”，也禁止用训练集结果对外。

6.4 机器人执行边界

平台负责目标点、状态、任务和证据，不冒充已经完成机器人自主导航、避障、自动返航和自动充电。与硬件组的接口至少包括：

接口	平台发送	机器人回传
任务	task_id、目标经纬度、优先级	ACK、拒单原因
状态	查询或控制指令	navigating、collecting、done、fault
遥测	无	位置、电量、航速、仓容、故障码
证据	上传地址或上传凭据	作业前后影像、重量、复核结果

真实硬件达到 E3 前，宣传中统一使用“机器人协作单元”和“作业端接口”，不使用“完全自主无人船”。

7. 核心指标体系

7.1 感知指标

指标	口径	当前状态	目标证据
泡沫 precision	独立测试集，按目标匹配	未测	不低于 80%
泡沫 recall	独立测试集，按目标匹配	未测	不低于 70%
事件级误报率	确认事件中现场不存在的比例	未测	由试点数据决定门槛
发现时延	真实目标出现到事件确认	合成环境可测	形成分层统计
时序链路误报抑制率	被时序过滤的检测数 / 输入检测数	合成链路约 76%；不是识别精度或召回率	真实视频重新标定并报告样本量、分母和置信区间

以上数值是研发目标，不是当前成绩。

7.2 调度与执行指标

指标	定义	目标
派单成功率	形成合法有效任务的派单尝试比例	不低于 99%
重复建单率	同事件产生的非预期重复任务	0
ACK 成功率	设备收到任务并确认的比例	按实网统计
ACK 时延	下发到 ACK 的耗时	P95 目标低于 5 秒
重派成功率	ACK 超时后可重新分配的比例	不低于 90%
任务闭环率	形成完整状态、重量和证据的任务比例	不低于 90%
设备在线率	可用时间 / 应服务时间	按试点考核
数据完整率	必填业务字段齐全的工单比例	不低于 99%

7.3 商业与治理指标

指标	定义	用法
每吨综合清理成本	总成本 / 已验收吨数	与人工清运成本比较
每闭环任务成本	总成本 / 完整闭环任务数	判断调度效率
每监测点年成本	硬件折旧 + 通信 + 维护	报价基础
空驶距离占比	无有效作业航行距离 / 总航行距离	衡量 Agent 调度价值
治理响应时延	发现到任务开始	政府考核指标
纠纷或复核率	被质疑或需复查的任务比例	数据可信度

8. 商业模式与市场验证

8.1 商业逻辑

项目不试图创造一个完全不存在的新预算，而是切入政府已经在支出的人工巡查、临水打捞、设备维护和治理汇报流程。第一阶段的核心产品是“智能监测与调度服务”，不是单纯卖船。

三种收入模式：

1. 政府购买服务：监测点位服务费、任务运营费、按验收清理量计费。
2. 设备销售或租赁：面向景区、环保公司、园区和其他作业单位。
3. 数据与生态服务：环境数据订阅、治理绩效接口和未来的生态价值服务。

8.2 连江首发策略

首发场景不追求全县铺开，而是选择 1 个乡镇、1 至 2 个固定点位和 1 个可控作业单元。成功判据不是签约金额，而是：

- 有明确责任人和使用流程。
- 能连续运行一个有效周期。
- 产生事件、任务、清理和异常的真实记录。
- 形成用户签字或用印的试用反馈。
- 能算出至少一次真实单位成本。

8.3 商业数字纪律

当前 docs/business-model.md 中的 1.52 万元原型机成本、875 元每吨人工成本参照、650 元每吨服务价、11 万元试点年营收和三年回报均为测算。正式计划书应增加：

- 每项数字的来源类型：公开资料、供应商询价、用户访谈或团队假设。
- 询价日期和报价有效期。
- 敏感性上下限。
- 若核心变量不成立的替代方案。

在取得采购意向、试点协议、验收单或回款前，所有数字必须标记“测算，不构成成交承诺”。

同样，不能用单一“清理了 X 吨”替代成本和闭环质量。

8.4 市场路径

市场范围按证据逐级解锁：

1. 连江单乡镇试点：验证问题、流程、成本和用户价值。
2. 连江多乡镇复制：验证跨点位调度和运维。
3. 福州与福建沿海复制：验证气候、监管和预算差异。
4. 全国沿海及内陆水域：只有在标准化交付和售后能力形成后进入。

不预先给出缺乏底稿的全国市场规模。任何 TAM、SAM、SOM 必须附计算表、来源和假设。

9. 十二周推进计划

第 1 周：建立可信基线

- 安装缺失测试依赖。
- 修复 Windows 契约脚本编码。
- 重新执行完整测试并保存原始输出。
- 初始化版本控制，对当前工程打基线标签。
- 锁定本计划书为唯一对外口径。

验收结果：

- 完整测试全绿。
- README 和产品分析中的测试数量与结果同步。
- `git status` 可追踪所有改动。

第 2 至 3 周：Agent Runtime 最小闭环

- 建立 Run、Step、Memory、Approval、Policy、Tool Registry。
- 实现事件读取、设备查询、派单计划、任务创建、任务查询和轨迹记录。
- 提供结构化成功和失败结果。
- 保持外部模型可选，确定性模式必须独立运行。

验收结果：

- 一个事件触发完整 run。
- 能处理成功、无机器人、工具错误、策略拒绝、审批拒绝和重复触发。
- API 返回完整步骤和终止原因。

第 4 周：数据库与 API 完成

- 新增 Agent ORM 和数据库结构。
- 增加 Alembic 迁移。
- 完成运行、步骤、审批、工具和评测 API。
- 写审计事件和权限控制。

验收结果：

- 迁移可重复执行。
- API 契约测试通过。
- 管理员、操作员、查看者权限边界明确。

第 5 至 6 周：前端智能体控制台

- 替换静态 AgentsView。
- 展示运行、轨迹、工具、审批、错误和回放。
- 提供空状态、失败状态和降级状态。
- 演示端到端可操作。

验收结果：

- 不再出现固定的“6 个智能体在线”文案。
- 所有状态来自真实 API。
- 桌面和移动尺寸均可读可操作。

第 7 周：感知评测

- 建立样本清单、标注规范和授权记录。
- 封装评测脚本。
- 输出指标 JSON、分层结果和失败样本。
- 将 OpenCV、候选模型和未来模型纳入同一评测接口。

验收结果：

- 每次评测可复现。
- 结果能直接生成答辩图表。
- 训练集和独立测试集隔离。

第 8 周：数据完整性和报告

- 解决 coverage_area 无数据源问题。
- 增加字段完整率、异常任务和闭环审计。
- 建立成本与清理量的真实口径。

验收结果：

- 报表不再输出无法解释的数字。
- 每个指标能追溯到原始事件和任务。

第 9 周：系统级评测与可靠性

- 完成模拟设备、Redis、MQTT、数据库异常测试。
- 增加 Agent 固定评测集。
- 建立回放和回归流程。

验收结果：

- 有性能、恢复和失败轨迹报告。
- Agent 变更不能通过伪造测试通过。

第 10 周：真实或准真实场景验证

- 优先完成真实设备、码头或养殖区短时验证。
- 如无法出海，完成用户在场的水槽、码头或半开放环境验证。
- 记录设备、环境、输入、结果和失败。

验收结果：

- 至少形成一条 E3 证据，不能只停留在计划。

第 11 周：商业证据和材料

- 完成用户访谈、供应商询价和试点方案。
- 获取意向、会议纪要或明确反馈。
- 更新成本模型和单位经济性。

验收结果：

- 所有商业数字有来源。
- 至少一个潜在用户对流程 and 价格给出明确意见。

第 12 周：比赛级总验收

- 打磨八分钟演示。
- 完成答辩题库和证据附件。
- 进行三次无提示彩排和一次故障演练。
- 核对所有对外数字。

验收结果：

- 主链路现场可复现。
- 任一模块失败时仍能解释降级路径，且文档、代码、演示和答辩口径一致。

10. 团队与执行体系

10.1 必备角色

角色	责任	不能由谁兼任的边界
项目负责人	方向、资源、对外承诺和最终验收	不能同时充当唯一测试人
Agent 与后端负责人	Runtime、策略、工具、数据和 API	不能自行批准自己提交的高风险策略
感知负责人	数据、标注、评测、模型和边缘部署	不能只报告有利于结论的指标
硬件负责人	船体、机构、电气、安全和现场测试	不能由软件人员替代安全结论
产品与运营负责人	用户流程、试点、成本、需求和反馈	不能只做 PPT，不做真实访谈
前端负责人	业务控制台、实时状态和可访问性	不能展示后端不存在的状态
测试与质量负责人	独立验证、证据保存和回归门禁	不能只执行 happy path
指导教师或行业顾问	技术审核、资源连接和场景指导	不能替代团队完成项目主体

10.2 协作规则

- 每个工作包必须有负责人、输入、输出、截止时间和验收命令。
- 每个数字有唯一来源。
- 每个 API 有契约和调用方。
- 每个 Agent 工具有 Schema、权限和失败测试。
- 每个高风险动作有审计和审批策略。
- 任何“完成”必须附带可复现证据。
- 不并行修改同一文件的相邻区域；共享接口先冻结，再分派。

11. 风险清单

风险	概率	影响	预防	触发后的应对
Agent 做成表演层	高	高	先落 Run、Step、Tool、Policy	暂停前端扩展，回到 Runtime
现场数据和硬件延误	高	高	同步推进准真实测试	主动标注 E2，改讲软件闭环
真实海况误报	高	高	固定约束、时序校验、负样本	聚焦泡沫和白天平潮
MQTT 或网络不稳定	中	高	幂等、PEL、补派、本地队列	现场使用本地 Broker 和故障演示
成本估算失真	高	中	供应商询价和敏感性分析	降级为区间，不给单点承诺
政府预算周期长	高	高	先做小额试点和效果付费	调整里程碑，不以签约时间绑技术
知识产权被抢	中	中	软著、专利、数据授权和保密协议	保留时间戳与研发记录
比赛材料过度包装	中	极高	证据分级和统一术语	立即撤回并修正全部材料
团队成员流失	中	高	文档化、角色备份、代码可持续	启动替代负责人

12. 比赛答辩设计

12.1 八分钟演示结构

1. 30 秒：一个真实乡镇治理场景和当前痛点。
2. 60 秒：系统不是卖船，而是解决发现、派单、执行和核算。
3. 150 秒：现场触发事件，Agent 展示计划、工具调用、派单和轨迹。
4. 90 秒：展示误报复核、无机器人、审批拒绝和恢复能力。
5. 90 秒：展示治理报表、单位成本和证据链。
6. 60 秒：用户、试点路径和商业假设。
7. 60 秒：团队、壁垒、风险和下一步。

12.2 必须准备的证据附件

- 用户访谈纪要和现场照片。
- 数据授权、隐私和影像使用说明。
- 数据集 manifest、标注规范和独立测试结果。
- 测试命令与原始输出。
- 模拟器配置、场景和统计口径。
- Agent 运行轨迹、失败样本和评测报告。
- 硬件 BOM、供应商询价和实物照片。
- 试点协议、意向书、会议纪要或反馈记录。
- 软著、专利和开源许可证清单。
- 成本模型、计算表和敏感性分析。

12.3 不能依赖的答辩方式

- 只播放预录视频。
- 用无数据源的图表支撑结论。
- 所有操作都由演示者手工触发，Agent 没有自主轨迹。
- 评委追问后无法指出代码、接口、测试或数据位置。
- 网络断开后主链路完全不可演示。

13. DeepSeek Harness 分工开发方案

13.1 分派原则

DeepSeek Harness 不直接获得“把项目做好”这种模糊目标。每个工作包必须以文件边界、接口契约、验收命令和禁止事项为约束。共享接口先由总控冻结，再并行开发。

仓库已有 .git，但当前包含大量尚未提交的增量；在生成新基线前必须先完成全量回归、契约检查和文档口径同步。工作包之间按数据模型、Agent 内核、API、前端、评测、感知、商业文档六个边界拆分。共享文件如路由注册、模型导出、依赖文件由集成负责人统一修改。

13.2 工作包

工作包	范围	主要文件	验收
WP-00 基线修复	Pillow、编码、全量测试、版本控制	测试环境、脚本、README	已完成：当时 860 通过、0 跳过、0 失败；当前总控复核为 1012
WP-01 Agent 内核	Runtime、Run、Step、Tool、Policy、Memory	backend/app/services/agents/	已完成 E1：23/23 固定场景通过，支持可选 SQL 持久化恢复
WP-02 数据与迁移	ORM、SQL、Alembic	模型、迁移和初始化脚本	已完成代码与迁移验证；真实 PostgreSQL/PostGIS 环境仍需纳入部署验收
WP-03 API 与权限	运行、步骤、审批、工具和评测 API	API router、Schema、deps	已完成 E1：契约、权限和审计测试通过
WP-04 前端控制台	运行、轨迹、审批、回放	AgentsView.vue、API 客户端	已完成 E1：真实 API 数据；取消确认、viewer 权限、关闭与刷新恢复浏览器回归 3/3 通过
WP-05 评测系统	场景集、指标、回归和报告	backend/tests/agent_evals/、脚本	已完成 E1：固定场景一键执行并输出 JSON
WP-06 感知评测	数据集 manifest、OpenCV 评测、指标 API	ml/、edge/	部分完成：隔离与空集保护已完成；样本量为 0，报告为 not_evaluated
WP-07 数据完整性	coverage_area、闭环质量、报表口径	report、stats、schema	已完成 E1：无来源面积为 null，CSV 空值验收通过
WP-08 商业与材料	访谈、询价、成本、证据附件	docs/business-model.md、项目文档	模板和台账完成；真实访谈、询价、意向仍缺，无 E3/E4
WP-09 集成验收	契约、回归、演示和故障演练	跨模块集成	已完成 E1 收口：测试、契约、自证、前端构建和浏览器异常态回归通过；正式 DOCX 随本次交付重建并逐页验收
WP-18 Agent 真实状态验收	真实 HTTP/权限/PostgreSQL/审批/幂等/重启只读回放	Agent API、仓储、验收脚本、证据	已完成 E2：129/129；合成事件、进程内 Runtime，不覆盖真

工作包	范围	主要文件	验收
			实设备/海域/生产级

13.3 工作包交付格式

每个工作包返回：

状态：完成 / 部分完成 / 阻塞

修改文件：

实现内容：

关键设计：

执行的测试：

测试结果：

未完成事项：

风险与假设：

需要总控决策：

没有测试结果、文件清单和边界说明的输出，不视为完成。

13.4 并行边界

可以并行：

- Agent 内核与前端视觉框架。
- 数据库迁移与评测场景设计。
- 感知评测与商业材料。
- 数据完整性与答辩素材。

不能并行冲突：

- 多个工作包同时修改路由注册文件。
- 多个工作包同时修改根依赖文件。
- 多个工作包同时定义 Agent 状态枚举。
- 未冻结 API Schema 前开发消费该 API 的前端。

14. 总体验收标准

14.1 工程

- 完整测试通过，结果与文档一致。
- Agent Runtime 不依赖外部大模型即可运行。
- 所有工具调用有 Schema、权限、超时、幂等和审计。
- 成功、失败、取消、审批拒绝和超时都有轨迹。
- 关键数据库迁移可重复执行。

14.2 产品

- 用户能从告警走到任务完成和报表。
- 用户能看懂 Agent 做了什么、为什么做、何时需要介入。
- 无机器人、工具故障和网络异常时有明确状态。
- 不支持的能力在界面上显示为不可用，不伪造状态。

14.3 数据与模型

- 数据集有授权、版本和 manifest。
- 训练、验证、独立测试不泄漏。
- 指标有分母、样本量、分层和置信区间。
- 合成数据、准真实数据和真实数据严格区分。

14.4 商业

- 每个商业数字有来源级别和更新日期。
- 访谈、询价、意向、协议和验收分别归档。
- 至少验证一个用户的流程和付费意愿。
- 明确“试点验证”和“商业成交”的边界。

14.5 比赛

- 八分钟内主链路可现场运行。
- 评委可以随机追问技术、数据、成本和风险。
- 每个关键结论都能指向代码、测试、数据或附件。
- 项目在创新、技术、产品、商业和团队五个维度口径一致。

15. 立即执行顺序

1. Agents 页面浏览器回归已经完成 3/3, WP-18 Agent 真实状态软件集成验收已完成 129/129: 真实 HTTP/权限/PostgreSQL、WRITE 审批、幂等和重启只读回放均有证据; 结果见 artifacts/browser-acceptance/latest.json 与 artifacts/agent-real-state-acceptance/latest.json。
2. 从本计划书重建正式 DOCX, 逐页渲染检查, 清理所有旧基线和无来源数字; 计划书、评委/产品分析和 Harness 手册必须保持同一证据口径。
3. 冻结当前代码与文档基线; 在用户明确要求前不添加远程、不推送。
4. 通过 DeepSeek Harness 继续执行 WP-06 感知数据和 WP-08 商业证据工作包; 子代理只处理文件边界明确、验收命令明确的任务。
5. 优先取得至少 1 份真实访谈、1 份真实询价和 1 次准真实/现场测试记录, 把项目从 E1 推向 E3 起点。
6. 每周至少完成一次真实证据更新; 没有新证据的功能不计入比赛进度。

本计划书不能代替真实订单、真实数据、真实硬件和现场测试。它的价值在于把团队的工作从“堆功能”约束到“形成可以经受评委、用户和工程验证的证据链”。只要这条证据链成立, 项目才具备真正稳定的国奖候选力。