探海灵眸 • 系统评测与验证佐证

参赛辅助材料 · 覆盖感知检测 / 智能体决策 / 系统集成 / 故障自证 · 原始报告见同目录「原始报告 /」

一、感知检测：第三方公开基准独立评测（2026-10-08）

基准数据集：SC-FloatWaste（HuggingFace OliviaWuYJ/sc-floatwaste；Zenodo DOI 10.5281/zenodo.21934286；CC BY 4.0），来源为现场摄像头与视频抽帧，区域覆盖印尼 Citarum 流域 / 澳大利亚 NSW / 塔斯马尼亚 Hobart，时间跨度 2021-10 至 2024-11。

测试集：400 张图像 / 1,490 个真值框；按数据集官方划分隔离（test 全部取自官方 val，不参与任何训练与调参）。

检测通道	模型 / 类型	输入尺寸	mAP50	mAP50-95	最佳 F1
监督微调通道	YOLO11 · 有监督微调	1280	0.514	0.344	0.538（P 0.567 / R 0.511）
零样本通道	YOLO-World · 开放词汇零样本	1280	0.116	0.074	0.242
零样本通道	YOLO-World · 开放词汇零样本	960	0.143	0.093	0.270

口径（照录原报告 claim_boundary）：本结果为第三方公开数据集上的独立测试集精度，非连江海域、非本项目设备实测；只能表述为「在公开漂浮垃圾基准上的独立评测精度」，不得表述为「连江现场验证」「真实海域验证」或「本项目设备实测精度」。

二、智能体决策：固定场景评测（证据等级 E1，2026-09-26）

27 个固定场景全部达成期望（success_rate 1.0），报告文件：原始报告 / 智能体固定场景评测_v2.json。关键指标：

指标	数值	含义
success_rate	1.0	27/27 场景达成期望（含预期失败的负向场景）
trace_replay_match_rate	1.0	轨迹回放与原始轨迹 100% 匹配
restart_recovery_rate	1.0	重启后续跑恢复率（全新仓储 + 全新 runtime）
idempotency_conflict_rate	1.0	幂等键 / 乐观锁冲突全部被正确拦截
approval_handoff_success_rate	1.0	跨角色审批交接成功率
model_fallback_rate	0.75	模型规划回退规则模式的比例（含超时 / 非法输出）
device_fault_recovery_rate	0.75	注入设备故障的恢复率

口径：E1（进程内确定性仿真；假模型客户端、内存设备孪生、SQLite），不构成真实模型、真实设备或现场验证证据。

三、真实状态集成验收（证据等级 E2，2026-09-19）

129 / 129 项检查全部通过。验收范围：真实 HTTP API、鉴权 / 授权、PostgreSQL 持久化、任务创建、WRITE 审批门禁、幂等重放、进程重启后只读回放。报告文件：原始报告 / 真实状态集成验收_129 项.json。

口径：使用合成事件，不含真实相机、海域、用户或硬件证据。

四、受控故障注入自证（证据等级 E1，2026-09-19）

4 组共 127 项确定性用例全部通过（健康降级、ACK 启动恢复等）。报告文件：原始报告 / 受控故障注入自证_127 项.json。口径：进程内注入 / 内存 transport / scratch PostgreSQL，不代表真实 broker、公网或硬件故障。

五、自动化测试

全量 1061 项自动化测试通过（覆盖 backend / edge / ml 三个模块，pytest 统一收集）。

六、证据等级与口径声明

- 证据分级：E0 想法 / E1 代码与确定性仿真 / E2 多模块软件联调 / E3 真实设备或用户参与 / E4 合同订单回款验收。
- 本文全部结果处于 E1—E2；公开基准评测所用数据集为真实公开数据，但被测系统未在真实海域运行，不得据此宣称 E3 / E4。
- 42%～76% 仅指「时序链路误报抑制率」（被时序过滤的检测数 / 输入检测数），不代表识别精度、召回率或准确率。
- 全部原始报告以 JSON 形式存于同目录，含代码版本指纹、配置哈希与命令，可复跑、可复核。